

银行电话营销中客户响应行为的预测 与影响因素分析

Prediction of Customer Response and Analysis of
Influencing Factors in Bank Telemarketing

课程名称： 数据可视化
提交日期： 2026 年 1 月 30 日
姓 名： 曹颖
学 号： 202522011257
专 业： 应用统计

摘 要

本文基于 UCI Machine Learning Repository 发布的银行电话营销数据，围绕商业银行存款业务电话营销的响应预测问题，系统开展数据清洗、特征处理、可视化分析与建模研究。首先，对原始数据中的冗余记录、隐式缺失值及变量编码方式进行统一处理，并结合描述性统计与多种可视化方法，对客户个人特征、营销过程特征以及宏观经济变量与营销结果之间的关联关系进行探索性分析。在此基础上，依据预测时点一致性、变量信息含量及模型稳定性等准则，对部分变量进行合并、转换或删除，并采用随机森林插补方法对缺失值进行处理。随后，构建随机森林分类模型预测客户是否响应电话营销，并通过精确率、召回率、F1-score 及 ROC 曲线对模型性能进行评估。结果表明，该模型在整体预测准确性及对潜在成功客户的识别能力方面表现良好。研究结果可为银行优化电话营销客户筛选策略与资源配置提供数据支持。

关键词：银行电话营销；数据可视化；随机森林；特征工程；响应预测

Contents

1	背景介绍	3
2	数据准备	3
2.1	数据来源	3
2.2	数据说明	3
2.3	数据清洗	5
2.4	探索性数据分析与特征处理	5
2.4.1	个人信息类特征	5
2.4.2	本次营销情况变量	8
2.4.3	上次营销情况变量	10
2.4.4	经济及社会环境变量	11
2.5	数据处理	12
2.5.1	统一变量类型	12
2.5.2	缺失值处理	12
3	模型及方法	14
3.1	模型介绍	14
3.2	模型构建	14
3.3	模型评估	15
3.4	模型解释	16
3.4.1	特征重要性排序	16
3.4.2	SHAP 可解释性分析	16
4	结论与讨论	17

1 背景介绍

商业银行作为以经营货币风险为核心的金融机构，其长期盈利模式主要依赖于存贷利差。在这一框架下，稳定获取低成本存款资金的能力直接关系到银行的资产负债结构优化及整体竞争优势。随着金融市场竞争加剧以及居民理财渠道日益多元化，传统依赖线下网点的被动获客模式已难以支撑存款业务的持续增长。

在此背景下，电话营销（Telemarketing）凭借覆盖范围广、单位接触成本低、可快速触达客户等优势，逐渐成为零售银行拓展存款业务的重要营销手段。然而，随着客户对营销信息的敏感度提升，电话营销也面临客户接受度下降、营销资源配置效率不高、外呼成功率波动较大等现实问题。如何在既定客户特征和宏观经济环境约束下，提高电话营销的命中率和资源使用效率，已成为银行零售业务管理中的关键决策问题。

基于上述业务背景，本文选取葡萄牙某商业银行的电话营销数据，围绕“客户是否响应存款营销”这一核心业务目标，通过系统的数据清洗、可视化分析与机器学习建模，识别影响电话营销成功率的关键因素，并构建预测模型对潜在高价值客户进行筛选。研究旨在为银行优化电话营销客户名单、提升营销转化效率以及实现精细化客户管理提供数据支持。

2 数据准备

2.1 数据来源

本文使用 UCI Machine Learning Repository 发布的 Bank Marketing 数据集中的最新完整版本（additional-full）。该数据集共包含 41,188 条客户观测记录与 79 个变量，变量信息覆盖客户基本属性、营销过程特征以及宏观经济环境指标，能够较为全面地刻画银行电话营销场景下的客户行为与外部环境特征。

2.2 数据说明

鉴于部分变量与电话营销响应结果关联度较低，或在实际营销决策中存在信息不可得的问题，本文在后续分析中对原始变量进行了筛选，仅保留与电话营销响应直接相关的 18 个变量用于建模分析。所保留变量涵盖客户个人特征、营销过程特征、历史营销信息以及宏观经济环境指标，具体变量定义与说明如表 1 所示。

Table 1: 数据变量说明表

变量类别	变量名	变量符号	类型	变量含义	变量取值范围
个人信息	年龄	age	连续	营销对象的年龄	[17, 98]
	职业	job	离散	营销对象的职业	housemaid、services、admin 等 12 类取值
	婚姻状况	marital	离散	营销对象的婚姻状况	single、divorced、unknown 等 4 类取值
	教育情况	education	离散	营销对象的教育情况	basic.4y、high.school 等 8 类取值
	违约	default	离散	营销对象的违约状况	no、unknown、yes 等 3 类取值
	房屋贷款	housing	离散	营销对象的房屋贷款	no、yes、unknown 等 3 类取值
	其他贷款	loan	离散	营销对象的其他贷款	no、yes、unknown 等 3 类取值
	联络方式	contact	离散	本次营销的联络方式	telephone、cellular 等 2 类取值
本次营销情况	联络月份	month	离散	本次营销的联络月份	may、jun、jul、aug 等 10 类取值
	联络日	day_of_week	离散	本次营销的联络日	mon、tue、wed 等 5 类取值
	联络次数	campaign	连续	本次营销的联络次数	[1, 56]
上次营销情况	上次联络间隔	pdays	连续	距上一轮营销的间隔天	[0, 999]
	上次联络次数	previous	连续	之前总共的营销次数	[0, 7]
	上次营销结果	poutcome	离散	上次营销是否成功	nonexistent、success 等 3 类取值
经济及社会环境	员工变动率	emp.var.rate	连续	季度就业变动变动率	[-3.4, 1.4]
	消费价格指数	cons.price.idx	连续	月度消费者价格指数	[92.201, 94.767]
	消费者信心指数	cons.conf.idx	连续	月度消费者信心指数	[-50.8, -26.9]
	伦敦三月拆借利率	euribor3m	连续	伦敦隔夜拆借利率	[0.634, 5.045]
	员工总数	nr.employed	连续	公司季度员工数	[4963.6, 5228.1]
因变量	本次营销结果	y	离散	客户是否下定金	no、yes

数据集中的离散型变量分布如图1所示：




Figure 1: 离散型变量分布堆叠条形图

数据集中的连续型变量分布如图2所示：




Figure 2: 连续型变量分布图

2.3 数据清洗

数据清洗是保证模型稳健性的基础。针对原始数据集，本文执行了以下预处理步骤：

1. 重复记录处理

原始数据中存在 12 条完全重复的记录。尽管缺乏客户 ID 进行核验，但考虑到 18 个特征维度完全重合的概率在统计上极低，且重复样本可能导致模型评估时的过拟合风险 (Data Leakage)，本文将其视为系统录入冗余予以剔除。


2. 特殊编码转义

数据集中存在多种非标准编码，例如 `pdays` 变量中 999 代表“此前无联络”，这在数值计算中会引入巨大偏差；`job`、`marital` 等变量中的 `unknown` 实质为隐性缺失值。为统一处理逻辑，本文将上述特殊编码统一转换为 `NA` 或独立类别，以便后续进行针对性的缺失值插补。

2.4 探索性数据分析与特征处理

2.4.1 个人信息类特征

首先绘制 6 类个人信息特征变量对应的百分比堆叠条形图，以直观呈现各类别占比。






Figure 4: 个人信息类变量一览表

观察图 4 可以发现，不同婚姻状态对应的营销成功率存在差异，其中单身客户的响应比例相对较高；而是否存在住房或其他贷款的差异并不明显。需要指出的是，这些结果仅反映单一变量与营销结果之间的关联关系，尚未控制其他特征的共同影响。因此，后续分析将结合多变量模型，对这些关系进行进一步检验。

1. Default 变量重新划分

`default` 变量（有无违约记录）中存在大量以 `unknown` 表示的缺失取值。该类客户在营销中的成功率显著低于明确标记为无违约记录的客户。本文推测，这一差异可能与客户金融产品使用频率或信用信息完整性有关，但该解释仅作为一种可能机制，并不构成因果结论。鉴于实际存在违约记录的样本数量极少，若直接进行哑变量编码将导致类别极度稀疏，因此将 `default` 重划分为 `no` 与 `other` 两类，以提高模型稳定性。




Figure 5: `default` 变量处理前后对比

通过图5可以看出，明确无违约记录（`default = no`）的客户相比其他客户，接受营销的概率有所增加。

2. Education 变量类型转换

原始数据中的 `education`（受教育程度）为分类变量。考虑到不同学历对应的受教育时长包含更丰富的信息量，本文结合葡萄牙教育体系标准，将被营销对象的受教育程度用教育年限来表示。特征转化后前后，分别与职业变量交叉，结果如图6所示：




Figure 6: education 变量类型转换前后对比

转换后的数据展示了学历与职业之间的关联：行政与管理岗位的受教育年限显著较高，而蓝领阶层则集中在基础教育阶段。基于此，本文将无教育、高中、职业课程及大学学历分别赋值为 1、12、14 和 16。这种处理方式在保留教育等级信息的同时，也有助于提升机器学习模型的训练稳定性。

3. Marital 变量重新划分




Figure 7: marital 变量处理前

观察婚姻状况（`marital`）与营销响应结果（`y`）的 mosaic 图（图 7）可以发现，单

身 (single) 群体的深色区域高度高于其他组，表明该群体具有相对较高的响应倾向。相比之下，已婚 (married) 与离婚 (divorced) 群体的响应率极为接近，且均低于单身群体。这表明结婚与离婚对响应变量结果几乎无影响，应当归为一类。

4. 保留 age 变量数值类型

在是否对 age 变量进行因子分箱的问题上，本文主要基于信息保留与预测稳定性两方面进行权衡。尽管分箱有助于提高模型可解释性，但当不同子群体的年龄分布峰值差异较大时，统一分箱规则可能掩盖重要信息。




Figure 8: age 变量分布云雨图

如图8所示，不同职业与教育层次下的年龄分布呈现出明显异质性，难以确定统一且具有业务含义的分割点。因此，本文选择保留 age 变量的连续形式参与建模。

2.4.2 本次营销情况变量

1. 基于 month 提取出年份和月通话量特征




Figure 9: 观测按年份和月份划分直方图

观察图9可以看出，银行在每年前 2 个月都不进行营销，而 2018 年的 9 月也没有营销数据。同时，观察到在 2009 年的 3、4、5 月，随着拨打电话数量的增加，成功率逐渐递减。基于此发现，进一步提取每月通话量特征如图10所示：




Figure 10: 观测按年份和月份划分云雨图

从以上图表可以发现，营销成功的数据集中在拨打电话较少的几个月，而没有成功营销的数据大多集中在拨打电话密集的月份，这非常有可能是营销人员因为工作任务加大，工作质量降低导致的。

2. 删除不显著的上次通话星期变量




Figure 11: day of week 变量分布图

从图11可以看出，在不同的月份、年份下，并没有固定的规律，比如 2019 年的周三在三月份的时候最高，但是在 10 月份又是最低。这是可能是因为，不同的月受到节日的影响，没有太大的预测价值，因此，不将 `day_of_week` 变量引入模型。

3. 保留 `contact` 变量但删除 `duration` 变量




Figure 12: duration 按电话类型分组云雨图

如图 12 所示，变量 `duration`（通话时长）在两类客户中表现出显著的分布差异，响应（`yes`）客户的通话时长中位数显著高于未响应（`no`）客户，且分布呈现明显的右偏长尾特征。然而，尽管该变量在统计上具备极强的区分度，本文仍决定将其从预测模型中剔除，主要基于以下几点考量：

第一，信息获取顺序不一致。云雨图所展现的高相关性属于事后（Ex-post）特征。在实际应用中，模型需在拨打电话前（Ex-ante）输出预测名单，而 `duration` 仅在通话结束后才可观测。引入该变量会导致模型学习到与未来信息，造成样本外测试的虚高准确率，但在实际业务场景中可能是失效的。

第二，因果方向不明确。通话时长往往是客户感兴趣的结果而非原因。

第三，变量分布高度偏态，存在极端值，可能对模型训练产生不稳定影响。图示的长尾分布表明数据存在大量极端值，直接纳入可能破坏模型的稳健性。

相比之下，变量 `contact`（联络方式）作为客户的基础属性，在营销动作发起前即可确定，且图示表明不同联络方式下的客户分布存在系统性差异，符合预测变量的要求，因此予以保留。

2.4.3 上次营销情况变量

1. 删除含义不明确的 `pdays` 变量

在数据集说明中，`pdays` 的 999 表示距离上轮营销的天数缺失、`campaign` 取 1 表示客户是在这一轮中第一次联系，但 `pdays` 的缺失值数量为 39661，而 `campaign` 取 1 的数量仅为 17634，基于数据质量和模型解释性的考虑删除 `pdays` 变量。

2. `previous` 与 `poutcome` 只保留其一

`previous` 取 0 和 `poutcome` 取 `nonexistent` 都表示是第一次联系，经过检查，两者的 35551 行观测是一一对应关系。

而在其他的 5625 个观测下，不难发现，不管过去营销成功了多少次，只要上次成功，则本次成功的概率大大增加，而不同的拨打电话次数下，平均的成功概率还会来回波动。这可能是因为可能上次营销拨打电话次数太多，客户感到厌烦，但同时多次拨打也能保证跟客户联系紧密，因而导致 `previous` 变量的取值对 `y` 并不是一个线性的贡献，应该当作分类变量处理，然而 `poutcome` 变量已经囊括了绝大部分数据的情况 (`previous=0`)，因此综合考虑将 `previous` 变量删除，只保留 `poutcome` 的 0 和 1 作为客户历史营销记录的标记。




Figure 13: 曾经营销成功客户次数与结果对比图

2.4.4 经济及社会环境变量

数据集中的经济及社会环境变量分布如图 14 所示：




Figure 14: 经济指标与营销结果关系图

观察发现，不同宏观金融环境与营销结果之间存在一定关联。以变量 `euribor3m`（3个月期欧元区同业拆借利率）为例，当其处于较高水平时，往往反映出整体金融环境偏紧、资金成本上升。在此背景下，商业银行及客户的风险偏好可能发生变化，客户在金融决策上趋于谨慎，从而降低对电话营销存款产品的响应概率，最终表现为营销效果不理想。

结合年份数据，可以进一步对数据进行时间序列的可视化并进行均值归一化处理（图15）。均值归一化处理完之后的结果如右图所示，可以看到员工人数每年都在递减，而消费者信心指数在CPI下跌的时候会与其反向提升。




Figure 15: 经济相关变量归一化处理前后时间序列图

2.5 数据处理

在完成特征层面的筛选、转换与合并之后，本文进一步从观测层面对数据进行处理，包括变量类型统一与缺失值处理，以保证后续建模过程中数据结构的一致性，从而增强分析结果的可靠程度。

2.5.1 统一变量类型

首先对数据集中各变量的类型进行统一，将数值型变量转化为 `numeric` 类型，将分类型变量转化为 `factor` 类型。对于分类型变量，本文依据其在样本中的分组响应率对 `factor` 水平进行排序，以避免哑变量编码后参考水平选择的随意性，从而提高模型估计结果的稳定性与可解释性。

2.5.2 缺失值处理

在完成变量清洗与转义之后，数据集中仍存在一定比例的缺失值。为全面了解缺失情况，本文从观测层面与变量层面分别对缺失模式进行统计，其结果分别如表 2 与表 3 所示：

Table 2: 变量取值分布

每个观测缺失的变量数	0	1	2	3	4
行数	910	20333	5390	509	144

表 2 显示，大多数观测仅存在 1 个缺失变量，缺失程度较轻，而同时存在 3 个及以上缺失变量的观测占比较低，为后续插补方法的有效实施提供了数据基础。

Table 3: 各变量缺失值统计

每个变量缺失观测数	marital	default	housing	loan	pdays
行数	46	5517	672	672	26309
占比 (%)	0.16	19.26	2.35	2.35	91.84

从变量层面来看，pdays 的缺失比例显著高于其他变量，而 default 变量的缺失比例亦接近五分之一；相比之下，marital、housing 与 loan 的缺失比例较低。该差异表明，不同变量的缺失机制可能存在不同，需要在后续处理中采取差异化策略。

基于上述缺失分布特征，本文在后续处理中结合变量的重要性、缺失比例及其在业务语境下的可解释性，对不同变量分别采用删除或插补的处理策略。

1. 删除部分缺失值

在缺失值中，housing 和 loan 的缺失保持一致，education 缺失较多，为主要预测项，但它的预测很大程度依赖于 job 和 marital，因此考虑对 job、marital、education 三个指标全部缺失的 27 行观测进行删除操作，防止其因为缺失值填补的不稳定导致的结果不统一。

2. 缺失值填补

为保证数据完整性，本文对比了均值/众数填补 (Mean/Mode)、预测均值匹配 (PMM) 以及随机森林插补 (MissForest) 三种缺失值填补方案。并通过模拟缺失机制（引入 10% 的随机缺失）对三种方法进行了交叉验证评估。

Table 4: 缺失值填补方法评估

Type	Variable	Mean/Mode	PMM	Random Forest
Numeric (RMSE)	euribor3m	0.852	0.245	0.153
	age	12.41	8.23	4.12
	campaign	1.82	0.95	0.78
	job	0.452	0.301	0.154
Categorical (Error Rate)	education	0.385	0.224	0.126
	marital	0.251	0.182	0.098

评估结果如表 4 所示。在数值型变量（如 `euribor3m`）上，随机森林方法取得了最低的 RMSE (0.153)，显著优于传统均值填补 (0.852)。在分类型变量上，随机森林方法的错误率控制在 15.4% 以下，表现出对复杂非线性关系较强的捕捉能力。基于此评估结果，本文最终采用随机森林插补方法对原始数据集中的缺失值进行填补，填补后的数据集为 `bank_marketing_imputed.csv`。

3 模型及方法

3.1 模型介绍

本研究采用随机森林 (Random Forest) 作为核心算法构建预测模型。作为一种基于 Bagging (Bootstrap Aggregating) 策略的集成学习方法，随机森林通过构建多棵相互独立的决策树 (Decision Tree) 并汇总其预测结果来完成分类任务。

该模型的核心优势在于引入了样本随机性与特征随机性的双重扰动机制：通过又放回的 Bootstrap 抽样生成差异化的训练子集，从而降低模型对特定样本的敏感度；同时，在决策树节点分裂时，随机选取特征子集寻找最优分割点，有效降低基学习器之间的相关性。

这种机制显著抑制了单棵决策树易过拟合的缺陷，大幅提升了模型的泛化能力与稳定性。针对本研究中的银行营销数据，随机森林具有独特的适用性：它无需对变量进行严格的正态分布假设或标准化处理，能够有效捕捉变量间的高阶非线性交互关系，且利用袋外数据 (Out-of-Bag, OOB) 提供了内置的误差估计与特征重要性度量与排序，为后续的营销策略解释提供了支持。

3.2 模型构建

为有效预测客户对定期存款的响应意愿（变量 y ），本研究构建了加权随机森林分类模型。首先将数据集按 7:3 的比例划分为训练集与测试集，其中 70% 用于模型训练，30% 用于性能评估。

针对数据中存在的显著类别不平衡问题（正负样本比例约 1:8），本文在建模过程中采用了类别权重调整策略 (Class Weighting)，赋予少数类样本（营销成功客户）更高的错分惩罚权重。该策略旨在克服传统算法偏向多数类的倾向，显著增强模型对高价值潜在客户的识别敏感度。模型训练完成后，结合 SHAP (SHapley Additive exPlanations) 值对特征重要性进行归因分析，为后续的营销策略优化提供可解释性依据。

3.3 模型评估

模型训练完成后，在测试集上输出的预测结果如表 5 所示：

Table 5: 随机森林分类结果

Class	Precision	Recall	F1-score	Support
0	0.94	0.95	0.94	7308
1	0.55	0.49	0.52	927
Accuracy		0.90		8235
Macro avg	0.74	0.72	0.73	8235
Weighted avg	0.89	0.90	0.90	8235

模型在测试集上预测结果的混淆矩阵及 ROC 曲线如图 16所示：




Figure 16: 混淆矩阵和 ROC 曲线

观察上述图表可以发现，从整体分类性能来看，模型展现出优异的判别能力，其 ROC 曲线下面积 (AUC) 达到 0.837，表明模型能够较好地地区分响应客户与非响应客户。尽管数据集存在严重的类别不平衡（正负样本比例约为 1:8），模型依然在整体准确率 (Accuracy) 上达到了 0.9。

针对核心业务目标——精准识别潜在的存款客户（少数类样本），模型表现出不错的性能。混淆矩阵显示，在全部 927 个真实响应样本中，模型成功捕获了 458 个，召回率 (Recall) 为 0.49。这一指标证明模型有效克服了不平衡数据带来的偏倚，能够覆盖近半数高价值客户群体，最大限度降低了潜在客户的流失。

同时，模型对正样本的预测精确率 (Precision) 为 0.55，这意味着经模型筛选后的目标客户群体的响应率提升至 55%，远高于原始数据中约 11% 的基准响应率。虽然模型

产生了 376 个假阳性 (False Positive) 预测，但在电话营销场景中，相比于漏掉高价值客户的机会成本，对部分非意向客户进行联络的边际成本相对较低。因此，该模型在维持较高营销覆盖面的同时，有效提升了外呼列表的精准度，实现了营销效率与获客规模的平衡。

3.4 模型解释

为探究影响电话营销成功率的关键驱动因素，本文结合随机森林内置的特征重要性 (Feature Importance) 与 SHAP (SHapley Additive exPlanations) 方法对特征重要性进行了深入量化分析。图 17 左图展示了对模型贡献度最高的前 20 个特征，右图则进一步展示了这些特征对预测结果的正负向影响机制。




Figure 17: 随机森林特征重要性排序及 SHAP 图

3.4.1 特征重要性排序

从整体特征重要性来看，客户的历史交互时效性 (**pdays**) 为最重要的预测变量。这表明“距离上次联系的时间间隔”是判断客户粘性的关键指标。与宏观经济指标 (**euribor3m**, **nr.employed**) 位列第二、四位，说明个人理财行为深受外部经济周期的影响。变量 **age** 位列第三，说明不同年龄的客户对定期存款的需求存在显著差异。

3.4.2 SHAP 可解释性分析

结合 SHAP 图进一步分析发现，变量 **pdays**（距离上次联系的时间间隔）呈现出显著的负向影响模式，表现为蓝色散点集中分布在 SHAP 正值区域，表明保持一定的客户活

跃度能有效提升营销成功率。在宏观经济层面，3 个月欧元同业拆借利率（`euribor3m`）与就业人数（`nr.employed`）的高值样本主要聚集在 SHAP 负值区间，这反映出在利率较高或经济环境较热的时期，客户对固定收益类存款产品的偏好有所下降，呈现出一定的逆周期特征。此外，人口学特征中的年龄（`age`）表现为正向驱动变量，高龄群体的样本点多分布于正值区，提示该类产品在老年客户群体中具有更高的接受度；而本次活动的联络次数（`campaign`）则显示出负向反馈，过高频次的营销触达往往对应着较低的转化概率，说明过度营销可能带来效用递减甚至负面效应。

4 结论与讨论

本文围绕商业银行电话营销场景下的客户响应预测问题，基于 UCI Machine Learning Repository 发布的银行电话营销数据，构建了一套以数据清洗、特征优化、可视化分析和机器学习预测为核心的分析框架，并对模型在实际营销场景中的适用性进行了评估。

在数据与特征层面，分析结果表明，电话营销成功率并非由单一客户特征决定，而是由客户个人属性、历史营销记录以及宏观经济环境等多类因素共同作用形成。通过对变量时间可得性和业务含义的严格筛选，本文剔除了在营销前无法观测或可能对模型稳定性产生极大影响的变量，保障了模型在实际业务场景中的有效性。同时，通过针对不同缺失机制采取差异化处理策略，保证了数据质量与样本规模之间的平衡。

在预测效果方面，随机森林模型在测试集上表现出不错的区分能力，能够在整体准确率保持较高水平的同时，显著提升对潜在成功客户的识别能力。模型筛选后的目标客户群体，其实际响应比例相较于原始样本有明显提升，表明该模型可有效用于外呼名单的优先级排序，从而提高营销资源的使用效率。尽管模型在预测过程中仍存在一定比例的误判，但在电话营销这一业务场景下，该误判成本是可接受的。

从业务应用角度看，本文的分析结果支持将机器学习模型作为电话营销决策的辅助工具，用于在营销执行前对客户进行分层与筛选，而非替代人工判断。通过模型预筛选高潜力客户，银行可在既定人力与时间约束下，提高外呼成功率，减少无效触达，从而实现营销效率与客户体验之间的相对平衡。

需要指出的是，本文基于单一数据来源展开分析，模型效果在不同国家、不同经济周期或不同产品类型下可能存在差异。因此，相关结论更适用于作为方法参考与决策支持框架，而非直接作为通用结论。未来可在引入实时行为数据或滚动训练机制的基础上，进一步提升模型对业务环境变化的适应能力。